Optimisez la gestion des données d'une boutique avec R ou Python

Laurent EBEDE OBAMA

Data Analyst

30.07.2025

Analyses Exploratoires des Données

1- Datasets

octobre uniquement

- **Extraction de l'erp de l'entreprise** :
  - 825 observations
  - 6 variables : identifiant du produit , prix d'achat et de vente, état du stock, etc
- **Extraction du site web de vente des produits**:
  - 1513 observations
  - 29 variables : caractéristiques des produits, quantités vendues, date d'introduction dans le site , etc
- **Table de liaison** :
  - 825 observations
  - 2 variables : id de l'article dans la table erp et id web de l'article dans le site internet

2 - Traitements réalisés

- **Identification et traitement des érreurs** :
  - **Données du site web** :
    - **Valeurs manquantes** : Articles n'ayant aucune information sur les ventes
    - **Erreur de contradiction** : Doublons (post_type, total_sales et product_type).
    - **Erreur de formatage** : L'identifiant web de l'article n'est pas toujours au même format

Analyses Exploratoires des Données

2 - Traitements réalisés

- **Identification et traitement des érreurs** :
  - **Données de l'erp** :
    - **Valeurs aberrantes** : valeurs négatives pour les prix et les stocks de quantités
  - **Table de liaison**
    - **Erreur de formatage** : l'identifiant web de l'article n'est pas toujours au même format
    - **Valeurs manquantes :** articles sans correspondance dans la table des données web

- **Création des fonctions, des variables et des indicateurs**:
  - Fonction qui compte, pour chaque article, le nombre d'occurrence de l'identifiant web
  - Pourcentage d'augmentation des prix, pour traiter les données manquantes
  - Prix de vente et prix d'achat hors taxe
  - Chiffre d'affaires
  - Nombre de mois de stock
  - Taux de marge de chaque article

Analyses Exploratoires des Données

3 - Remarques et difficultés rencontrées

- Absence du dictionnaire de données : l'interprétation de certaines variables est difficile et chronophage.

- Il n'existe pas une méthode objective pour gérer les valeurs aberrantes : risque d'adopter une méthode entrainant des résultats biaisés.

- Une pléthore d'information recueillie dans le site web, mais pas toujours nécessaire.

- Perte d'information sur la vente de certains articles : identifiant web non disponible.

Fusion ou consolidations des données

1 - Jointure de la table sur l'erp et la table de liaison

- **Clés utilisées** : l'identifiant de l'article
- **Jointure appliquée**: **Left join**. La table sur l'erp était la table principale. Elle a été complétée par les données de la table de liaison
- **Vigilance particulière** : la table obtenue doit avoir exactement le même nombre de lignes que la table principale. Il ne doit pas avoir des lignes en double

2 - Jointure de la table obtenue de la jointure précédente et la table sur les données du site web

- **Clés utilisées** : l'identifiant web de l'article. Les variables id_web et sku
- **Jointure appliquée**: **Left join**. La table de résultat de la jointure précédente était la table principale. Elle a été complétée par les données du site web
- **Vigilance particulière** : la table obtenue doit avoir exactement le même nombre de lignes que la table principale
- **Difficultées** : Certains articles n'ont pas d'identifiant web. Toutes les obervations de la table principale ne matchent pas avec les observations des données du site web.

Analyses univariées du prix

Méthodes statistiques employés

- Distribution de l'article selon sa disponibilité en stock
- Calcul des tendances centrales
- Identification des outliers : calcul du **z-score** et **l'intervalle interquartile**

Distribution du prix de vente selon la disponibilité de l'article

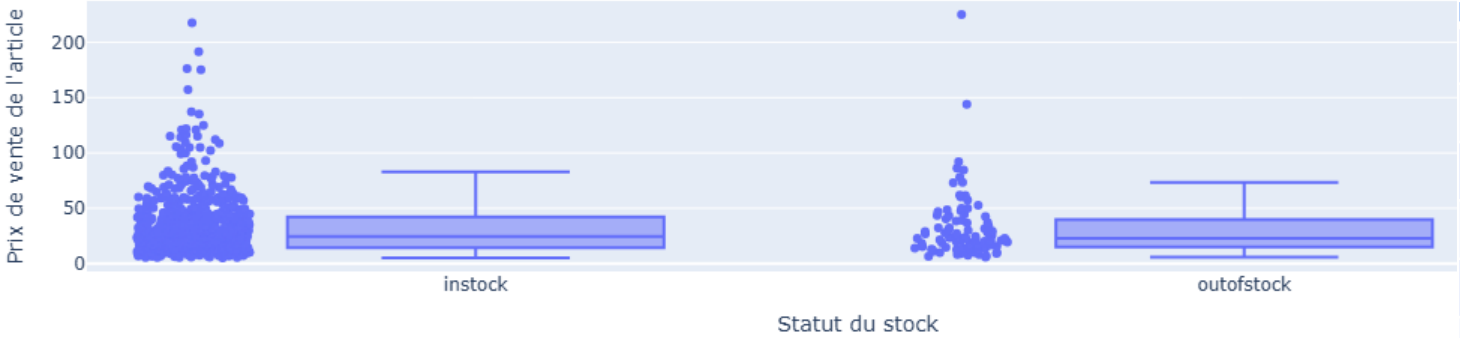

Description du prix de vente

Nombre d'articles	825
Prix moyen	32,27
Ecart type du prix	26,6
Prix minimum	5,2
1er quartile	4,5
Médiane	24,3
3e quartile	42
Prix maximum	225

Outliers

- **Z-score** : prix supérieur à 114 euros, soit 16 articles (1,94% des articles du catalogue)
- **Intervalle interquartile**: 36 articles (4,36% des articles)
- **Outliers justifiés :** il s'agit des produits haut de gamme

Analyse des quantités et du chiffre d'affaires

Méthodes statistiques employés

- Calcul du chiffre d'affaires par article et par type de produit
- Calcul du nombre d'articles représentant 80% du CA (20/80)

Chiffre d'affaires des ventes des 20 meilleures articles

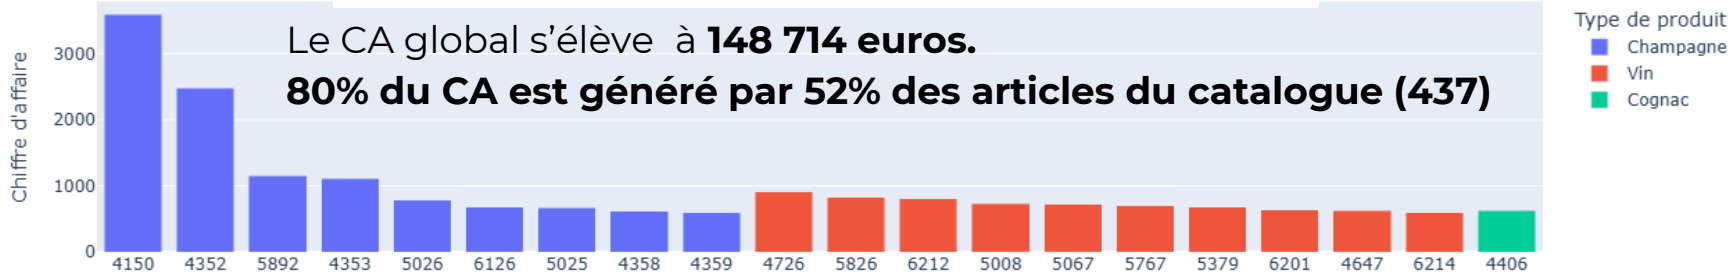

Nombre de vente des 20 meilleurs articles

Analyse des quantités et du chiffre d'affaires

Méthodes statistiques employés

- Calcul du chiffre d'affaires par article et par type de produit
- Calcul du nombre d'articles représentant 80% du CA (20/80)

Distribution du chiffre d'affaires selon le type de produit

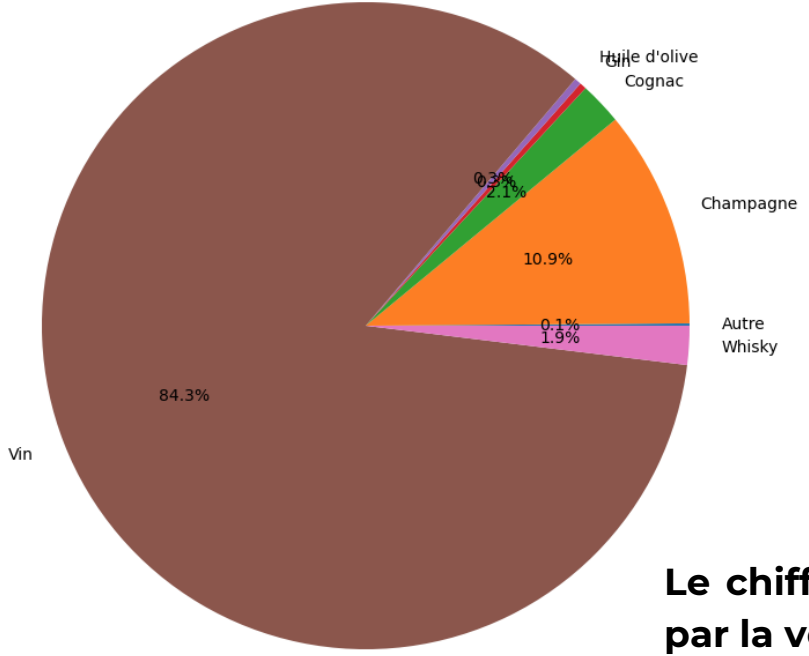

Récapitulatif des ventes d'article

Produit	Qté	Prix moyen	CA (en euros)
Autre	7	25	175
Champagne	224	69,62	16 173,6
Cognac	35	97,5	3 170,2
Gin	14	36	504
Huile d'olive	22	24,93	497,7
Vin	5 566	29,28	125 307
Whisky	48	65,55	2 886,6

Le chiffre d'affaires du site est principalement généré par la vente du vin, suivi du champagne.

Analyse des stocks

Méthodes statistiques employés

- **Calcul du nombre de mois de stock** : Rapport entre les qtés en stock et les qtés vendues
- Calcul de la valeur des stocks

Produit	Qtés en stock	Qtés vendues	Nbre de mois de stocks
Autre	23	7	3,28
Champagne	2 894	224	12,91
Cognac	99	35	2,82
Gin	11	14	0,78
Huile d'olive	158	22	7,18
Vin	13 470	5 566	2,42
Whisky	85	48	1,77

Description des stocks

Distribution de la valeur des stocks selon le type de produit

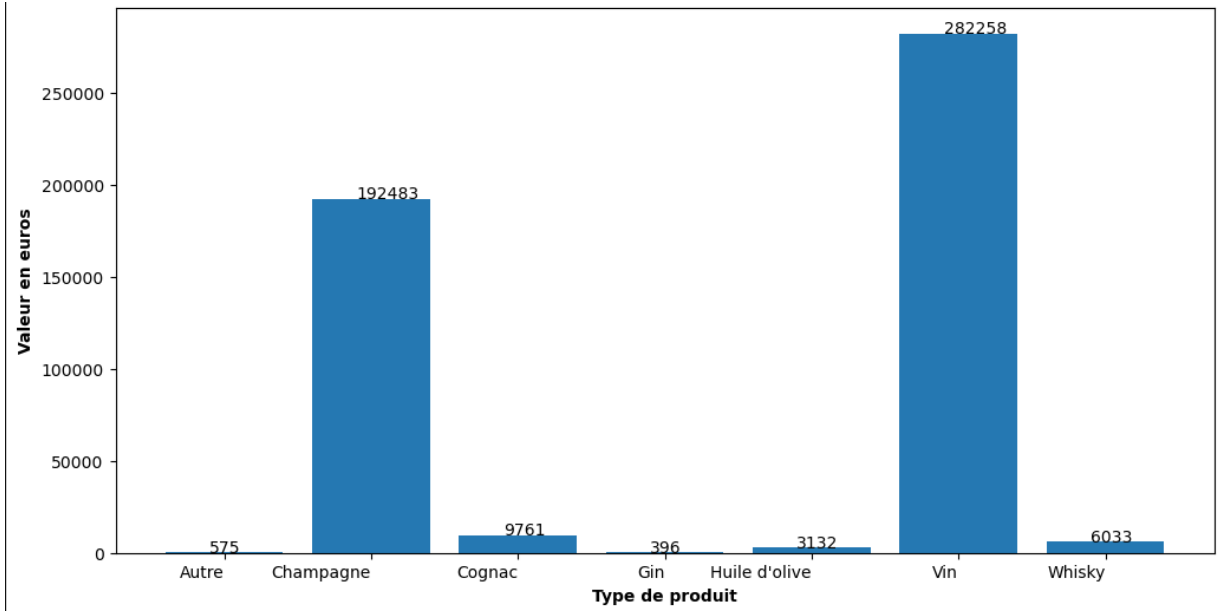

Le champagne a du mal s'écouler comparé au vin

Pour le vin la valeur des stocks est **2 fois** plus importante que les ventes du mois. Et **11 fois** plus importante pour le champagne

Taux de marge

Méthodes statistiques employés

Calcul : **(PV HT – PA HT) / PA HT**

Taux de marge par type de produit

Les marges les plus importantes sont réalisées sur le cognac et le whisky et non sur le vin

Étendu des taux de marge

Id produit	Type produit	Qtés en stock	Qtés vendues	PA	PV	CA	Taux de marge
4355	Champagne	97	0	77,48	12,65	0	-83,67%
4401	Cognac	5	3	27,21	62,5	187,5	129,29%
5916	Whisky	1	1	40,49	93	93	129,29%

Analyse des corrélations

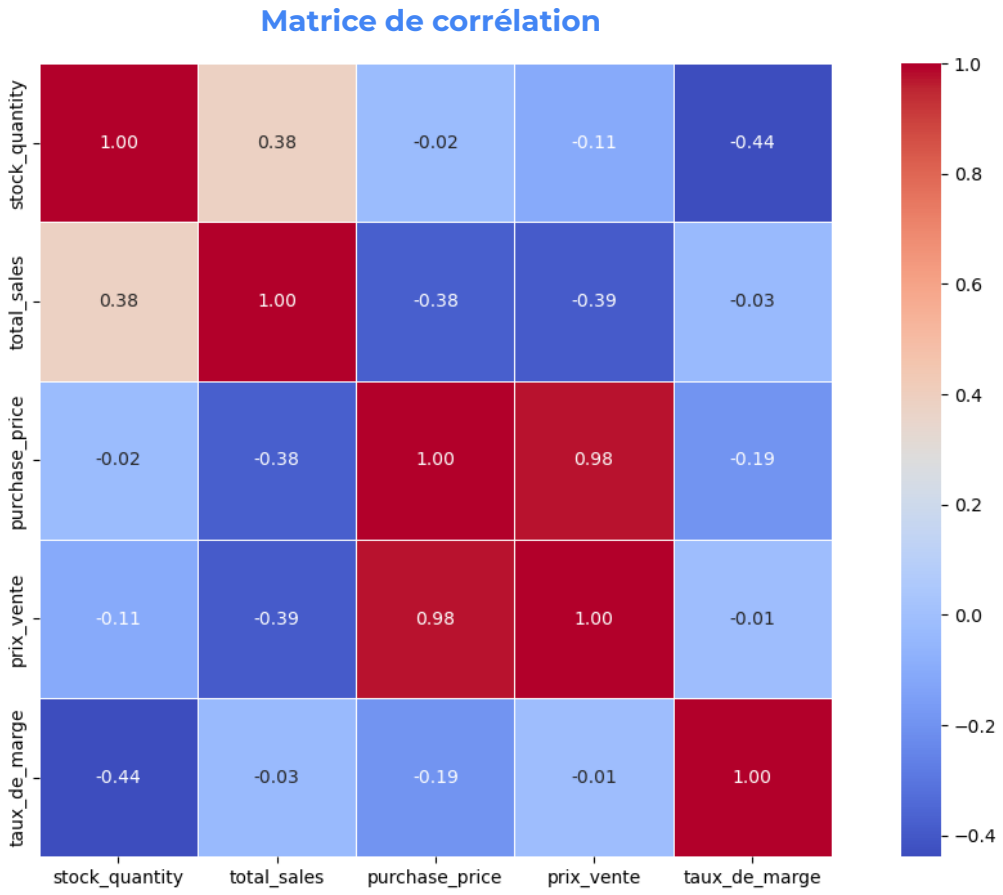

1. **Le prix de vente augmente avec prix d'achat**

2. **Pas de corrélation entre le prix de vente et le taux de marge:** le site ne gagne pas particulièrement de l'argent avec des articles haut de gamme

3. **Plus la quantité en stock est importante moins le taux de marge pratiqué est élevé:** Un stock important traduit des difficultés d'écoulement

4. **Plus le total des ventes est important moins les prix sont élevés :** les produits les plus vendus ont un prix bas. Donc les produits ordinaires

Amélioration à apporter dans le fichier de l’entreprise

1. **Améliorer la table de liaison entre l’erp et les données web.**
2. **Harmoniser les identifiants des articles sur le site web.**
3. **Recueillir uniquement les informations nécessaires dans le site web.**
4. **Définir un dictionnaire des variables.**

Conclusion

- Le champagne représente 11% du chiffre d’affaires, contre 84 % pour le vin.
- 2% à 4% d’articles du catalogue ont des prix anormalement élevés.
- La moitié des articles génèrent 80% du chiffre d’affaires.
- Seulement 2,5 mois de stock sont disponibles pour le vin.